Laporan Hasil Analisis Data Smart Agriculture

Mata Kuliah :

Big Data dan IOT

Disusun oleh :

Hafidz Ridwan Cahya (23082010093)

FAKULTAS ILMU KOMPUTER

PROGRAM STUDI SISTEM INFORMASI

UNIVERSITAS PEMBANGUNAN NASIONAL "VETERAN"

JAWA TIMUR

2026

DAFTAR ISI

1. Pendahuluan dan Deskripsi Dataset.....3
2. Langkah-Langkah Implementasi (Data Lifecycle)..... 4
A. Data Acquisition & Storage..... 4
B. Data Processing & Cleaning.....5
C. Data Analysis.....7
D. Data Visualization (Dashboard Streamlit).....10
E. Data Governance (Tata Kelola Data)..... 11
3. Hasil Analisis dan Insight Utama..... 12
LAMPIRAN.....12

1. Pendahuluan dan Deskripsi Dataset

Laporan ini menyajikan proses analisis dan manajemen siklus data (Data Lifecycle Management) pada data sensor Internet of Things (IoT) di sektor pertanian pintar (Smart Agriculture).

Dataset yang digunakan bersumber dari repositori publik (Kaggle) yang memuat 16.411 baris observasi data tanaman. Dataset ini berfokus pada kondisi lingkungan kunci yang memengaruhi tahapan pertumbuhan bibit, yang mencakup atribut:

- crop_id: Jenis tanaman (kategorikal).
- soil_type: Jenis tanah yang digunakan (kategorikal).
- seedling_stage: Fase pertumbuhan tanaman (kategorikal).
- MOI: Indeks Kelembaban (numerik).
- temperature: Suhu lingkungan dalam derajat celcius (numerik).
- humidity: Kelembaban lingkungan dalam persentase (numerik).
- result: Kelayakan/kualitas panen (1 = Baik/Sukses, 0 = Buruk/Gagal).

Tujuan dari analisis ini adalah untuk membersihkan data mentah, mengekstraksi insight (wawasan) terkait kondisi optimal lingkungan, dan memvisualisasikannya ke dalam dashboard pemantauan menggunakan platform streamlit.

2. Langkah-Langkah Implementasi (Data Lifecycle)

A. Data Acquisition & Storage

Pengumpulan data dilakukan menggunakan Kaggle Command Line Interface (CLI). Data mentah berformat .csv kemudian diamankan ke dalam struktur direktori lokal data/raw/.

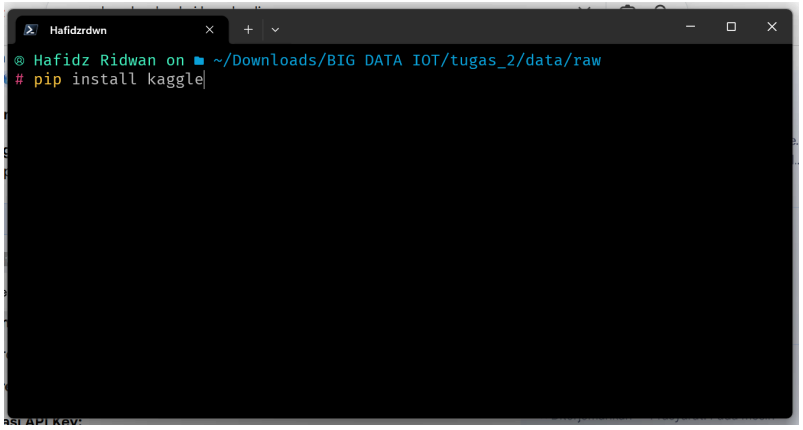

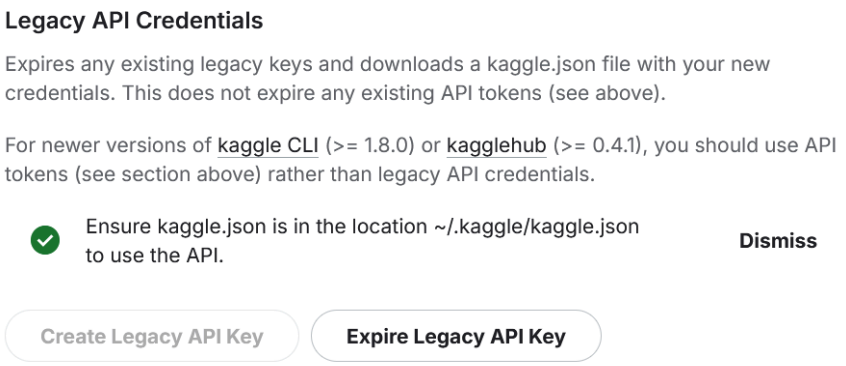

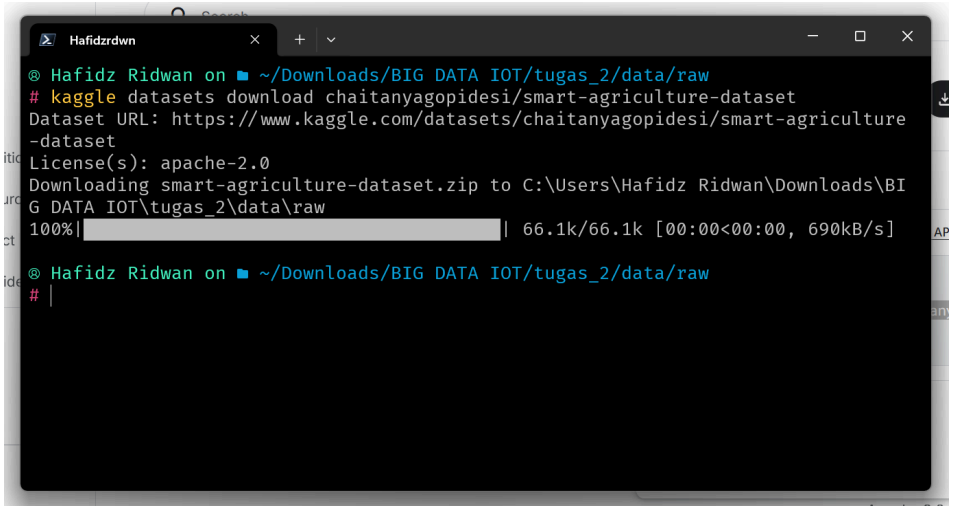

Lalu setelah data berhasil didownload, selanjutnya saya melakukan push raw data ke github repository

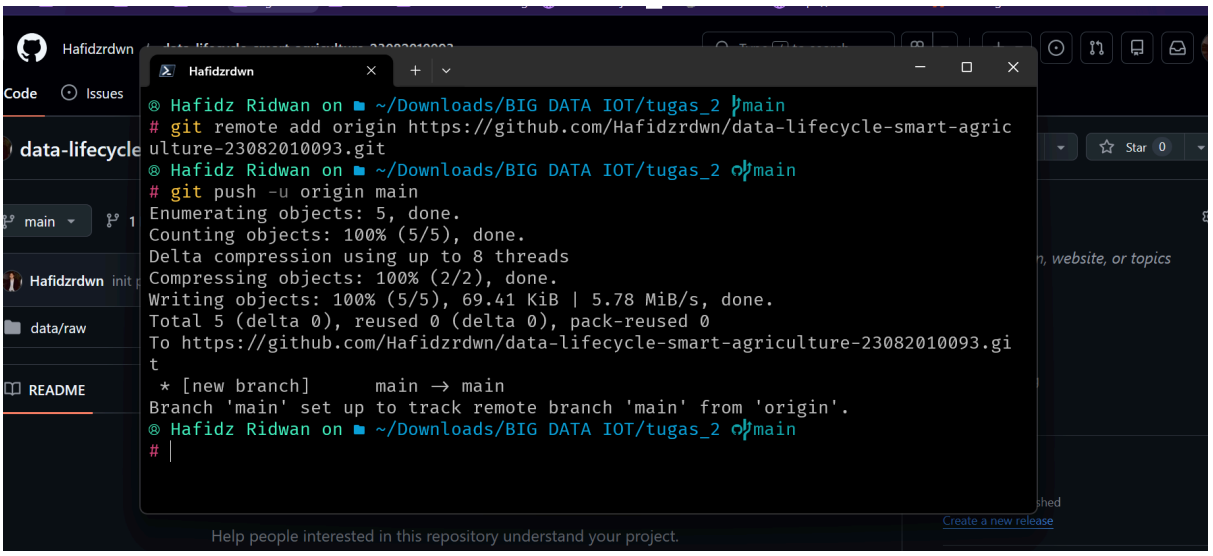

B. Data Processing & Cleaning

Proses pembersihan data dilakukan menggunakan bahasa pemrograman Python dengan library Pandas di lingkungan Jupyter Notebook/Google Colab. Langkah pemrosesan meliputi:

1. Standarisasi Kolom dan Tipe Data

```
[148]
✓ 0 d
# STANDARISASI NAMA KOLOM
df.columns = df.columns.str.lower().str.replace(' ', '_')
df = df.rename(columns={'temp': 'temperature'})
print(df.columns.tolist())

['crop_id', 'soil_type', 'seedling_stage', 'moi', 'temperature', 'humidity', 'result']
```

```
[149]
✓ 0 d
# CLEANING STRING VALUE
text_columns = ['crop_id', 'soil_type', 'seedling_stage']
for col in text_columns:
    if col in df.columns:
        # Ubah jadi string, hapus spasi depan-belakang, dan standarisasi huruf besar di awal kata
        df[col] = df[col].astype(str).str.strip().str.title()
        # Perbaiki tipe data jadi 'category' untuk menghemat memori
        df[col] = df[col].astype('category')
df.head()
```

2. Penanganan Nilai Kosong (Missing Values) dan Data Duplikat

```python
# CHECK MISSING VALUES
total = df.isna().sum()
percent = total/df.isna().count()*100
pd.DataFrame({'total':total,'percent':percent})
```

	total	percent
crop_id	0	0.0
soil_type	0	0.0
seedling_stage	0	0.0
moi	0	0.0
temperature	0	0.0
humidity	0	0.0
result	0	0.0

```python
# CHECK DATA DUPLIKAT
total_duplicated_data = df.duplicated(subset=['crop_id','soil_type','seedling_stage','moi','temperature','humidity','result']).sum()
print("TOTAL DATA DUPLIKAT :", total_duplicated_data)

df[df.duplicated(subset=['crop_id','soil_type','seedling_stage','moi','temperature','humidity','result'])]
```

```
TOTAL DATA DUPLIKAT : 128
```

	crop_id	soil_type	seedling_stage	moi	temperature	humidity	result
8511	Potato	Clay Soil	Seedling Stage	1	18	86.0	0
8512	Potato	Clay Soil	Seedling Stage	2	17	87.0	0
8513	Potato	Clay Soil	Seedling Stage	3	16	88.0	0
8514	Potato	Clay Soil	Seedling Stage	4	15	89.0	0
8515	Potato	Clay Soil	Seedling Stage	5	14	90.0	0
...	...	...	...	...	...	...	...
12313	Carrot	Sandy Soil	Flowering	65	19	85.0	0

3. Penanganan Anomali (Outliers)

Setelah pengecekan dilakukan perbaikan data dan pembersihan data

```python
# REMOVE DUPLICATES
baris_awal = len(df)
df = df.drop_duplicates()
baris_akhir = len(df)
print(f"\nDuplikat dihapus: {baris_awal - baris_akhir} baris")

print("Total Data Duplikat : ", df.duplicated().sum())
```

```
Duplikat dihapus: 128 baris
Total Data Duplikat :  0
```

```python
# HANDLE MISSING VALUES
df = df.ffill().bfill()

# HANDLE OUTLIERS
numeric_columns = ['moi', 'temperature', 'humidity', 'result']
for col in numeric_columns:
    Q1 = df[col].quantile(0.25)
    Q3 = df[col].quantile(0.75)
    IQR = Q3 - Q1
    batas_bawah = Q1 - 1.5 * IQR
    batas_atas = Q3 + 1.5 * IQR

    df[col] = df[col].clip(lower=batas_bawah, upper=batas_atas)
```

4. Sintesis Waktu (Datetime): Membangun kolom timestamp secara berurutan (reverse per 1 jam) guna memungkinkan analisis pergerakan data berbasis waktu (Time Series).

[155]
✓ 0 d

```
# penambahan kolom time series (dummy data)
waktu_sekarang = datetime.now()
df['timestamp'] = [waktu_sekarang - timedelta(hours=len(df)-i) for i in range(len(df))]
print("Kolom 'timestamp' berhasil ditambahkan!")
cols = ['timestamp'] + [col for col in df.columns if col != 'timestamp']
df = df[cols]
df.head()
```

```
Kolom 'timestamp' berhasil ditambahkan!
```

	timestamp	crop_id	soil_type	seedling_stage	moi	temperature	humidity	result
0	2024-05-01 04:32:21.974394	Wheat	Black Soil	Germination	1	25	80.0	1
1	2024-05-01 05:32:21.974394	Wheat	Black Soil	Germination	2	26	77.0	1
2	2024-05-01 06:32:21.974394	Wheat	Black Soil	Germination	3	27	74.0	1
3	2024-05-01 07:32:21.974394	Wheat	Black Soil	Germination	4	28	71.0	1
4	2024-05-01 08:32:21.974394	Wheat	Black Soil	Germination	5	29	68.0	1

Langkah berikutnya: Buat kode dengan df | New interactive sheet

C. Data Analysis

Data yang telah bersih dieksplorasi secara visual menggunakan Matplotlib dan Seaborn untuk menemukan pola tersembunyi. Pengujian yang dilakukan meliputi Correlation Heatmap (korelasi antar variabel) dan Boxplot distribusi suhu pada tiap fase pertumbuhan.

- CORRELATION HEATMAP (Korelasi Antar Sensor)

Tujuannya: Melihat seberapa kuat hubungan antar angka. Misalnya: Apakah kalau suhu (temp) naik, kelembaban (humidity) turun?

```python
# ANALISIS
# CORRELATION HEATMAP
sns.set_theme(style="whitegrid")
plt.figure(figsize=(8, 6))
korelasi = df[numeric_columns].corr()

sns.heatmap(korelasi, annot=True, cmap='RdYlBu_r', fmt=".2f", linewidths=0.5)
plt.title('Heatmap Korelasi: MOI, Temp, Humidity & Result', fontsize=14, pad=15)
plt.show()
```

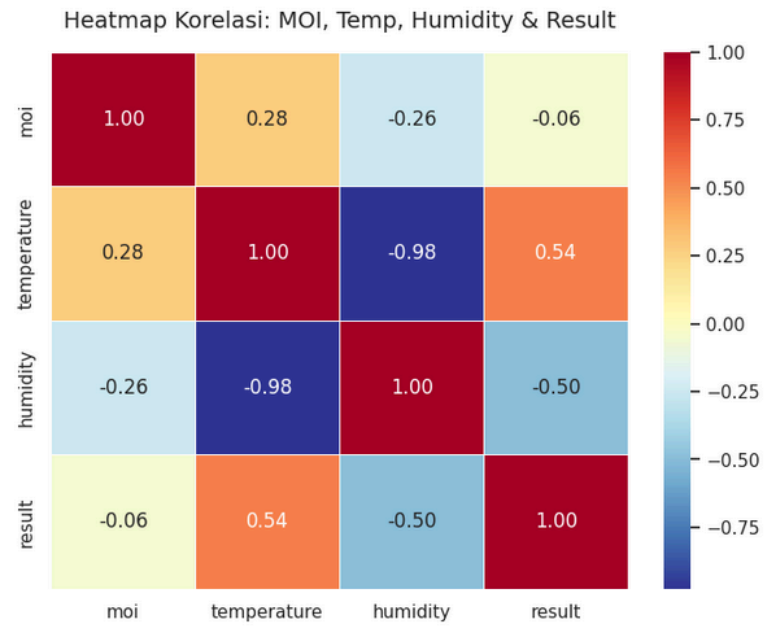

- TIME SERIES TREND (Tren Sensor Berdasarkan Waktu)

Tujuannya: Melihat fluktuasi sensor dari waktu ke waktu.

```python
# TIME SERIES TREND
print("--- GRAFIK TIME SERIES (RATA-RATA PER BULAN) ---")

df_monthly = df.set_index('timestamp').resample('ME').mean(numeric_only=True).reset_index()

df_monthly['Bulan'] = df_monthly['timestamp'].dt.strftime('%b %Y')

plt.figure(figsize=(14, 6))
sns.set_theme(style="whitegrid")

sns.lineplot(data=df_monthly, x='Bulan', y='temperature', label='Suhu (°C)', color='darkorange', marker='o', markersize=8, linewidth=2.5)
sns.lineplot(data=df_monthly, x='Bulan', y='humidity', label='Kelembaban (%)', color='dodgerblue', marker='s', markersize=8, linewidth=2.5)
sns.lineplot(data=df_monthly, x='Bulan', y='moi', label='MOI', color='mediumseagreen', marker='^', markersize=8, linewidth=2.5)

plt.title('Tren Rata-Rata Suhu, Kelembaban, dan MOI per Bulan', fontsize=16, pad=15, fontweight='bold')
plt.xlabel('Bulan (Periode)', fontsize=12)
plt.ylabel('Nilai Rata-Rata', fontsize=12)

plt.xticks(rotation=45)
plt.legend(title='Indikator Sensor', loc='upper right')
plt.tight_layout()
plt.show()
```

```
--- GRAFIK TIME SERIES (RATA-RATA PER BULAN) ---
```

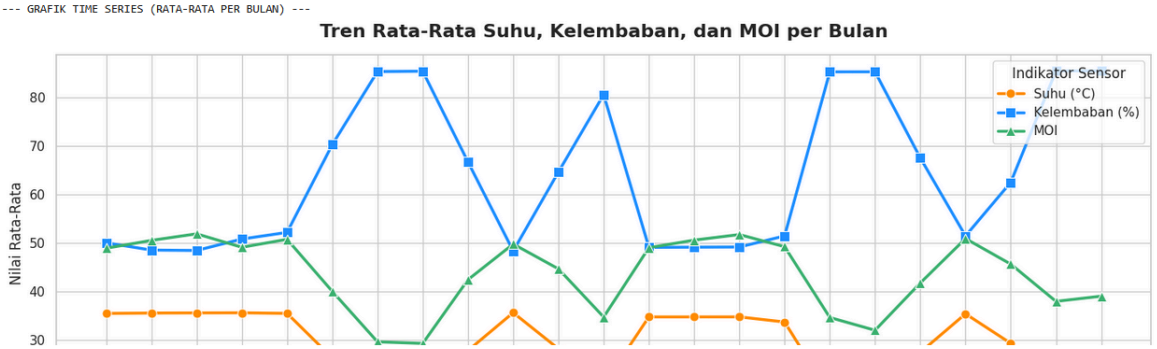

- BAR CHART KATEGORIKAL (Distribusi Tipe Tanah)

Tujuannya: Ingin tau observasi paling banyak ada di tipe tanah (soil_type) apa?

```
# BAR CHART DISTRIBUSI TIPE TANAH
plt.figure(figsize=(10, 5))
sns.countplot(data=df, x='soil_type', hue='soil_type', legend=True, order=df['soil_type'].value_counts().index)
plt.title('Distribusi Observasi Berdasarkan Tipe Tanah (Soil Type)', fontsize=14, pad=15)
plt.xlabel('Tipe Tanah', fontsize=12)
plt.ylabel('Jumlah Observasi', fontsize=12)
plt.show()
```

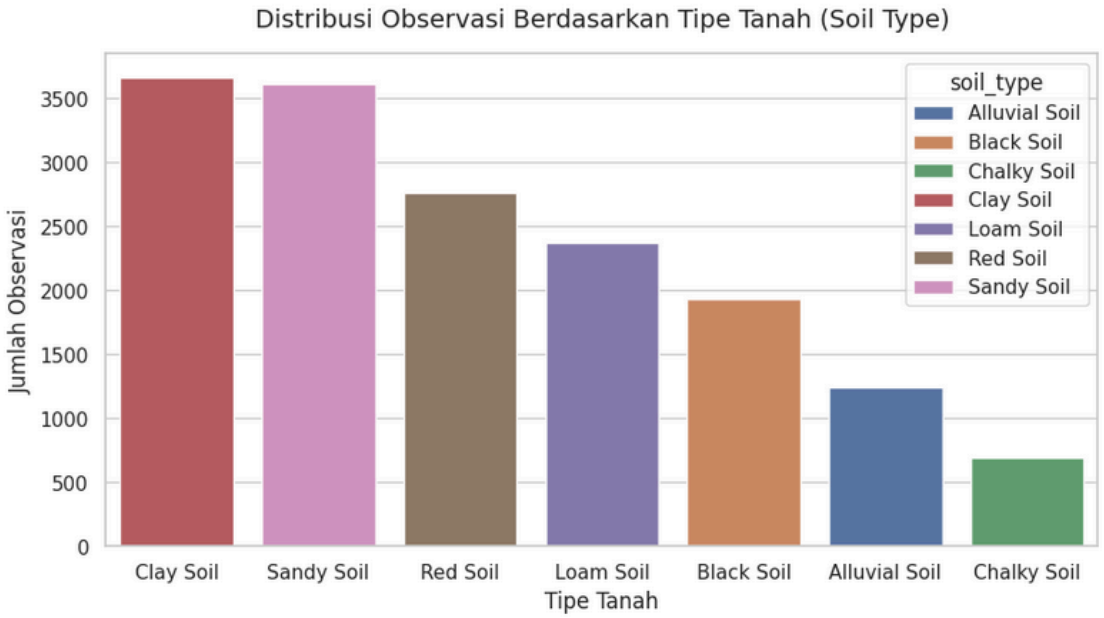

- BOXPLOT (Distribusi Suhu berdasarkan Fase Tumbuh)

Tujuannya: Melihat rata-rata dan penyebaran suhu (temp) di tiap fase pertumbuhan (Seedling Stage).

```
# BOXPLOT (Distribusi Suhu berdasarkan Fase Tumbuh)
sns.set_theme(style="whitegrid")
plt.figure(figsize=(12, 6))

sns.boxplot(
    data=df,
    x='seedling_stage',
    y='temperature',
    hue='seedling_stage',
    palette='Set2',
    legend=False,
    linewidth=2,
    width=0.6
)

sns.stripplot(
    data=df,
    x='seedling_stage',
    y='temperature',
    color='black',
    alpha=0.3,
    jitter=True,
    size=2
)

plt.title('Distribusi Suhu pada Setiap Fase Pertumbuhan', fontsize=16, fontweight='bold', pad=15)
plt.xlabel('Fase Pertumbuhan (Seedling Stage)', fontsize=12, fontweight='bold')
plt.ylabel('Suhu (°C)', fontsize=12, fontweight='bold')

plt.xticks(rotation=15)
plt.tight_layout()
plt.show()
```

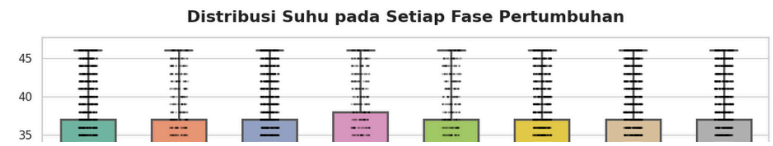

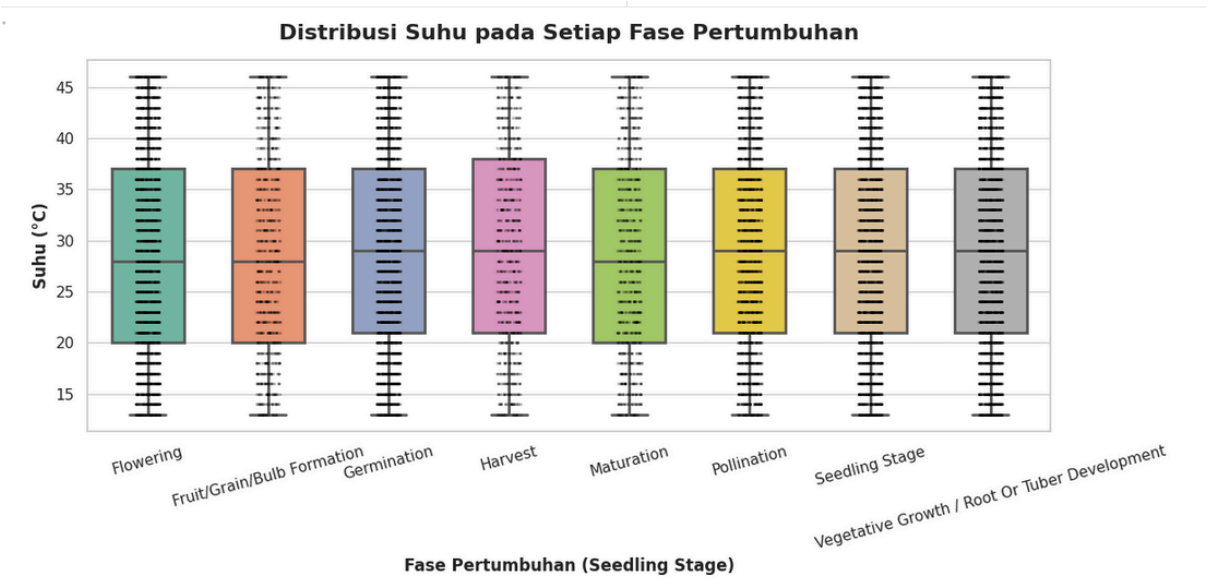

D. Data Visualization (Dashboard Streamlit)

Sebagai output akhir yang bernilai bisnis, data divisualisasikan menggunakan framework Streamlit menjadi dashboard interaktif yang mencakup:

- Time Series Chart (Dual Y-Axis): Menampilkan pergerakan tren Suhu vs Kelembaban dalam 7 hari terakhir.
- Gauge Meter: Indikator tingkat air/kelembaban.
- Alert System: Sistem peringatan dini berbasis threshold (Suhu > 32°C memicu status bahaya).

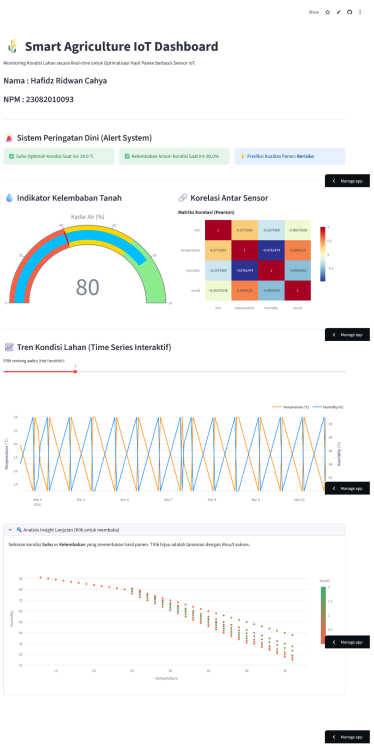

Link Dashboard: https://data-lifecycle-smart-agriculture-23082010093.streamlit.app/

E. Data Governance (Tata Kelola Data)

Untuk memastikan data layak digunakan sebagai dasar pengambilan keputusan, evaluasi Data Quality Score dilakukan pada hasil akhir (cleaned_data.csv). Skor yang didapatkan adalah:

- Accuracy (100%): Tidak terdapat data yang null/missing.
- Completeness (100%): Seluruh sel data terisi dengan format yang sesuai.
- Timeliness: Data historis 30 hari terakhir tersedia dan tervalidasi.

[156]
✓ 0 d

```python
print("=== HASIL DATA QUALITY SCORE ===")

# Hitung base metric
total_records = len(df)
total_cells = df.size
total_missing = df.isnull().sum().sum()

accuracy = 1 - (total_missing / total_cells)

total_non_null = df.notnull().sum().sum()
completeness = total_non_null / total_cells

end_date = df['timestamp'].max()
thirty_days_ago = end_date - pd.Timedelta(days=30)
data_last_30_days = df[df['timestamp'] >= thirty_days_ago].shape[0]

timeliness = data_last_30_days / total_records

print(f"Accuracy     : {accuracy * 100:.2f}%")
print(f"Completeness : {completeness * 100:.2f}%")
print(f"Timeliness   : {timeliness * 100:.2f}% (Jumlah data 30 hari terakhir: {data_last_30_days} baris)")
```

```
=== HASIL DATA QUALITY SCORE ===
Accuracy     : 100.00%
Completeness : 100.00%
Timeliness   : 4.43% (Jumlah data 30 hari terakhir: 721 baris)
```

3. Hasil Analisis dan Insight Utama

Berdasarkan pemrosesan dan visualisasi data yang telah dilakukan, ditemukan beberapa insight operasional yang krusial untuk sektor Smart Agriculture:

1. Korelasi Suhu dan Kelembaban (Berbanding Terbalik): Terdapat korelasi negatif yang kuat antara Suhu dan Kelembaban. Saat tren suhu lingkungan meningkat tajam pada siang hari, tingkat kelembaban (baik udara maupun MOI) cenderung menurun secara drastis. Ini mengindikasikan bahwa sistem irigasi (sprinkler) otomatis sebaiknya dijadwalkan menyala ketika suhu mendekati titik puncaknya untuk menyeimbangkan kelembaban.
2. Suhu Optimal Berdasarkan Fase Tumbuh: Berdasarkan analisis distribusi pada Boxplot, terlihat bahwa setiap fase pertumbuhan (Seedling Stage) memiliki toleransi suhu yang berbeda. Fase awal seperti Germination (perkecambahan) cenderung membutuhkan rentang suhu yang lebih stabil dan tidak terlalu fluktuatif dibandingkan fase pertumbuhan lanjutan.
3. Indikator Keberhasilan Panen (Result): Sebaran data pada grafik Scatter Plot menunjukkan bahwa tanaman dengan kualitas panen yang baik (result = 1) cenderung mengelompok di area dengan rentang suhu moderat (20°C - 30°C) dan tingkat kelembaban yang terjaga di atas 50%. Suhu ekstrem di atas 32°C yang dikombinasikan dengan kelembaban rendah secara signifikan meningkatkan probabilitas gagal panen.

LAMPIRAN

Link Github Repository :
https://github.com/Hafidzrdwn/data-lifecycle-smart-farming-23082010093/tree/main